CoDU: 단계적 접근을 통한 복합 문서 구조 이해 기법

김가빈[1], 이민혜[2], 서해인[3], 유제혁[3]
[1]덕성여자대학교 컴퓨터공학전공, [2]덕성여자대학교 소프트웨어전공, [3]덕성여자대학교 데이터사이언스학과
sunk2205@duksung.ac.kr, doreminye@duksung.ac.kr, angela040918@duksung.ac.kr, jhrew@duksung.ac.kr

CoDU: Multi-Stage Approach for Complex Document Structure Understanding

Kabeen Kim[1], Minhye Lee[2], Haein Seo[3], Jehyeok Rew[3]
[1]Department of Computer Science, Duksung Women's University
[2]Department of Software, Duksung Women's University
[3]Department of Data Science, Duksung Women's University

요 약

본 연구에서는 다양한 레이아웃과 시각적 요소가 혼합된 복잡한 문서 환경을 대상으로, 문서 구조 분석 성능을 향상시키기 위한 단계적 접근 방법인 CoDU(Complex Document Understanding)를 제안한다. CoDU는 YOLO 기반 문서 레이아웃 탐지 모델인 DocLayout-YOLO를 미세 조정하여 복잡한 문서의 바운딩 박스 검출 성능을 개선하고, 바운딩 박스 정제 과정과 읽기 순서 재정렬을 결합함으로써 문서 구조 분석 정확도를 향상하였다. 제안된 CoDU는 멀티 칼럼 구조, 이미지·표·수식이 혼재된 복잡한 문서에서도 기존 방법 대비 바운딩 박스 검출 및 읽기 순서 재정렬에서 향상된 성능과 강건성을 보였다. 실험 결과, CoDU는 기존 문서 구조 분석 시스템(Docling, DocFormer) 대비 바운딩 박스 검출 F1-score에서 최대 +0.475 향상되었으며, OCR 성능 지표인 정규화된 편집 거리를 기준으로 'Text'와 'Subtitle'에서 각각 0.615와 0.321로 가장 높은 정확도를 달성하였다. 또한, 읽기 순서 성능은 NED와 매칭 비율을 결합한 평가에 따라 평균 약 +0.2 향상되어, 복잡한 문서 환경에서도 일관된 분석 성능과 강건성을 확보하였다.

1. 서 론

최근, LLM(Large Language Model)과 RAG(Retrieval-Augmented Generation)를 활용한 새로운 정보 검색 패러다임이 부상함에 따라, 검색의 대상이 되는 보고서·발표 자료·제안서 등 다양한 형태의 문서에 기록된 내용을 정확하고 구조적으로 추출하는 기술의 중요성이 커지고 있다. 이러한 흐름 속에서, 문서의 시각적·공간적 구조를 해석하는 문서 구조 분석(Document Layout Understanding)은 정보 활용의 핵심 단계로 자리 잡았다. 그러나 실제 사용자에 의해 작성된 문서는 단순한 문자 나열이 아니라, 복합적인 레이아웃, 테이블, 이미지 등 서로 이질적인 요소들이 결합된 구조를 갖기 때문에 정확한 정보 추출이 어렵다. 특히, 기존 문서 구조 분석 시스템은 문자 인식에만 치중하여, 문서의 레이아웃과 전체적인 정보 흐름을 적절히 반영하지 못하는 한계가 존재하였다. 대표적으로, 오픈소스 툴킷 기반의 Docling[1]과 Transformer 기반의 DocFormer[2]는 기본적인 활용성은 우수하나, 복잡한 문서 구조 인식 과정에서 공통적인 취약점을 보인다. 이러한 한계는 바운딩 박스 겹침, 콘텐츠 간 불규칙한 간격, 객체 식별의 모호성, 멀티 칼럼 구성의 혼재 등에서 기인하며, 결과적으로 문서 구조 판별의 정확성을 저해한다. 또한, 콘텐츠의 올바른 순서를 식별하는 읽기 순서 성능 저하를 연쇄적으로 초래할 수 있다.

본 연구에서는 기존 문서 구조 분석의 한계를 완화하기 위해, 단계적 접근 방법인 CoDU(Complex Document Understanding)를 제안한다. 구체적으로, DocLayout-YOLO를 미세 조정하여 바운딩 박스 검출 정확도를 개선하였고[3], 이후 바운딩 박스 정제 과정과 읽기 순서 재정렬 단계를 결합하여 전체 문서 구조 분석 성능을 향상시켰다. 특히, CoDU는 멀티 칼럼 구조, 이미지·표·수식이 혼합된 문서 환경에서도 기존 모델 대비 일관된 성능 향상을 달성하였다. 본 연구에서는 모델의 범용성을 검증하기 위해 세미나 발표 자료, 학술 논문, 학술 대회 포스터 등 다양한 문서 유형을 활용하였으며, CoDU의 대표적인 분석 결과는 그림 1에 제시하였다.

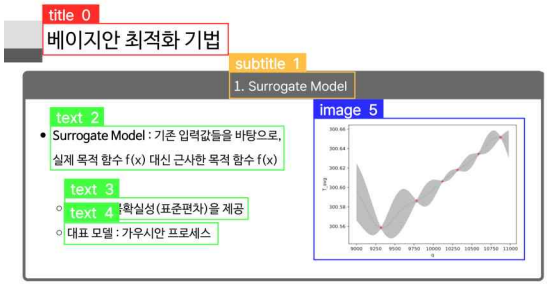


그림 1. 복잡한 문서 내 CoDU 사용 예시

2. 단계적 문서 구조 이해 방법

CoDU는 크게 바운딩 박스 검출 및 정제, OCR 기반 문자 인식, 읽기 순서 재정렬로 구성된다. 각 단계는 단순 문자 인식에 그치지 않고, 문서의 시각적 구조와 논리적 순서를 상호 보완적으로 반영한다. 특히, 바운딩 박스 정제 단계의 결과는 읽기 순서 재정렬 단계에서 활용되어 두 단계가 통합적으로 작동한다. 전체 처리 절차는 그림 2와 같다.

2.1. 바운딩 박스 검출 및 정제

본 연구에서는 문서를 'Title', 'Subtitle', 'Text', 'Table', 'Image', 'Equation'의 여섯 가지 클래스 분류를 목표로 한다. 문서 콘텐츠 영역을 탐지하기 위해 미세 조정을 적용한 DocLayout-YOLO 모델을 활용하였다. 사전 학습된 Do

이 성과는 정부(과학기술정보통신부)의 재원으로 한국연구재단의 지원을 받아 수행된 연구임(RS-2025-00516023).

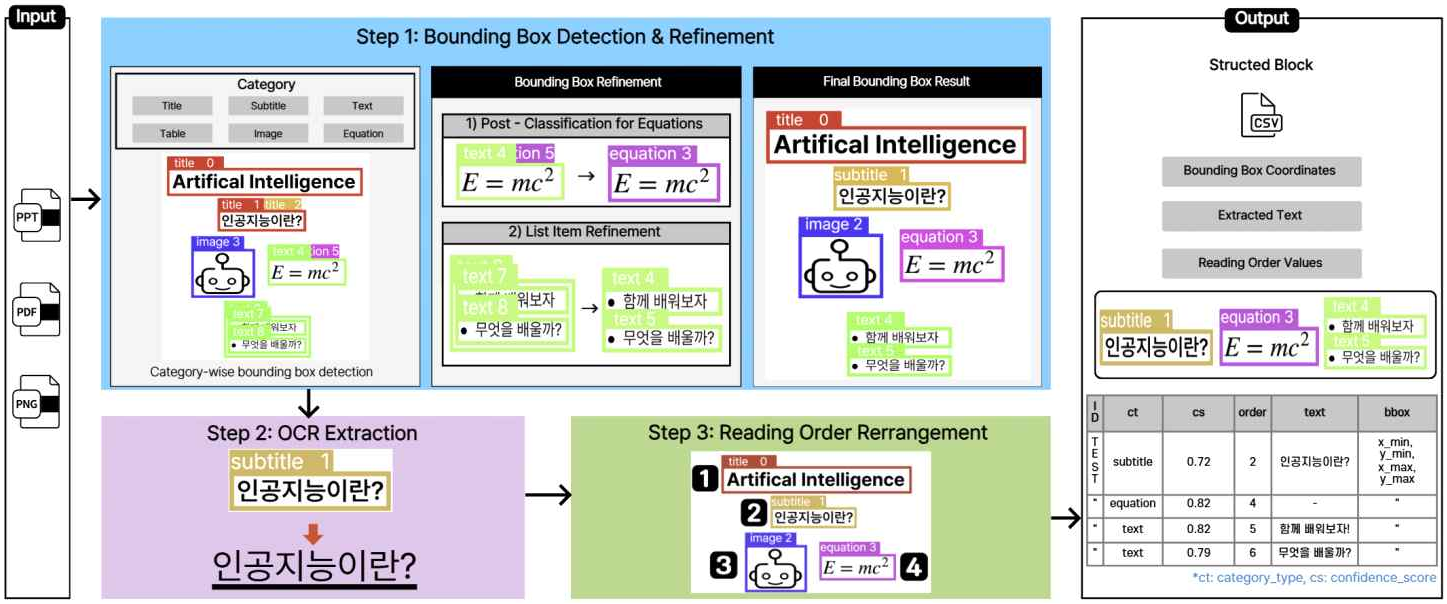


그림 2. 단계적 접근을 통한 복합 문서 이해 과정

cLayout-YOLO 모델에는 'Subtitle'이 포함되어 있지 않아, 이를 탐지하기 위해 'Subtitle'을 포함한 DocLayNet 데이터셋을 활용해 출력 레이어를 6개 클래스로 확장하였다[4]. 또한, 복잡한 레이아웃 탐지 성능을 강화하기 위해 자체 수집한 322건의 문서로 미세 조정을 수행하였다. 이러한 개선은 'Title'과 'Subtitle'의 공존 구조, 복잡한 'Equation' 인식, 멀티 칼럼 구성 등 실제 문서의 다양한 레이아웃 패턴에 대응하기 위함이다.

바운딩 박스 검출 이후, 수식 재분류와 글머리 항목 세분화를 통해 검출 결과를 정제하였다. 수식 재분류에서는 일부 수식이 'Text'로 잘못 분류되는 문제를 해결하였다. 바운딩 박스 내 문자열에 수학 기호(=, +, −, *, /, ^, (), ∫, Σ, Π, Δ)나 등식·연산 패턴(예: A = B, x + y)이 포함되면 해당 박스를 'Equation'으로 그림 3과 같이 재분류하였다.

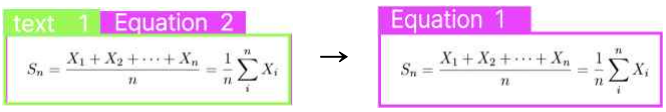


그림 3. 수식 재분류 전(좌) / 후(우) 예시

글머리 항목 세분화에서는 글머리 항목이 하나의 큰 바운딩 박스로 검출되는 문제를 해결하였다. 'Text'로 탐지된 영역에서 불릿 패턴(·, -, 숫자 등)을 식별한 뒤, 포괄 바운딩 박스를 제거하고 개별 항목만 그림 4와 같이 유지하였다. 전체 정제 과정의 알고리즘은 Algorithm 1에 제시하였다.

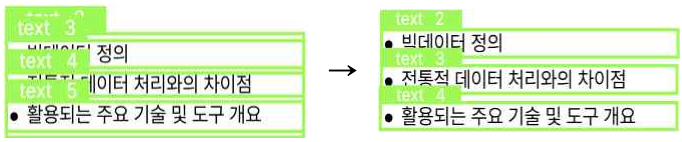


그림 4. 글머리 항목 세분화 전(좌) / 후(우) 예시

정제된 각 바운딩 박스 영역에 대해 PaddleOCR 3.0[5]을 적용하여 문자를 인식하였다. 이후, 정제 결과를 기반으로 문서의 논리적 읽기 순서 재정렬을 수행하였다.

2.2. 읽기 순서 재정렬

정렬된 바운딩 박스들을 기준으로 규칙 기반 알고리즘을 통해 최종적으로 사람이 실제로 읽는 순서에 따라 정렬하였다. 전체 과정은

Algorithm 1 Document Bounding Box Refinement

```
procedure REFINEMENT(boxes, items)
    for box in boxes do                                  // iterate boxes
        if box.class == "text" then                      // text box
            text ← box.text
            if contains_equation_symbols(text) then      // equation symbols
                box.class ← "equation"                   // reclassify
            end if
        end if
    end for
    if follows_list_structure(items) then                // list structure
        sort(items, in_descending_confidence_order)      // sort by score
        for item in items do                             // iterate items
            if not is_contained_by_other(item) then      // not nested
                add_to_refined_boxes(item)               // add to result
            end if
        end for
    end if
    return refined_boxes                                 // return result
end procedure
```

전폭 요소 분할, 칼럼 구조 판별, 순서 결정의 세 단계로 구성된다.

전폭 요소 분할 단계에서는 페이지 폭의 60% 이상을 차지하는 바운딩 박스를 전폭 요소로 정의하였다. 전폭 요소를 제외한 나머지 구간을 비전폭 요소로 설정하고, 해당 영역에서 본문의 칼럼 구조를 판별하였다.

칼럼 구조 판별 단계에서는 각 구간의 바운딩 박스의 중심 좌표를 추출한 뒤, K-means 클러스터링을 적용하여 좌우로 인접한 바운딩 박스들을 동일 그룹으로 묶었다. 클러스터 개수 k는 2~6 사이에서 데이터 분포에 따라 자동으로 결정되고, 각 클러스터가 하나의 칼럼에 대응되었다. 이를 통해 문서가 단일 칼럼인지, 멀티 칼럼인지 구분할 수 있었다.

순서 결정 단계에서는 단일 칼럼과 멀티 칼럼에 따라 다른 정렬 방법을 사용하였다. 단일 칼럼 문서에서는 바운딩 박스를 위에서 아래로, 왼쪽에서 오른쪽으로 정렬하였다. 구체적으로, 페이지 상단에 가까울수록 우선 배치되며, 같은 높이에서는 왼쪽에 위치한 바운딩 박스를 먼저 배치하였다. 즉, y 좌표 값이 작을수록 동일한 y 좌표 값에서 x 좌표 값이 작은 바운딩 박스를 우선 배치하는 것이다. 멀티 칼럼 문서에서는 칼럼 전체를 왼쪽에서 오른쪽으로 정렬한 뒤, 각 칼럼 내부에서는 위에서 아래로 바운딩 박스를 정렬하였다. 읽기 순서 알고리즘은 그림 5, 전체 알고리즘은 Algorithm 2에 제시하였다.

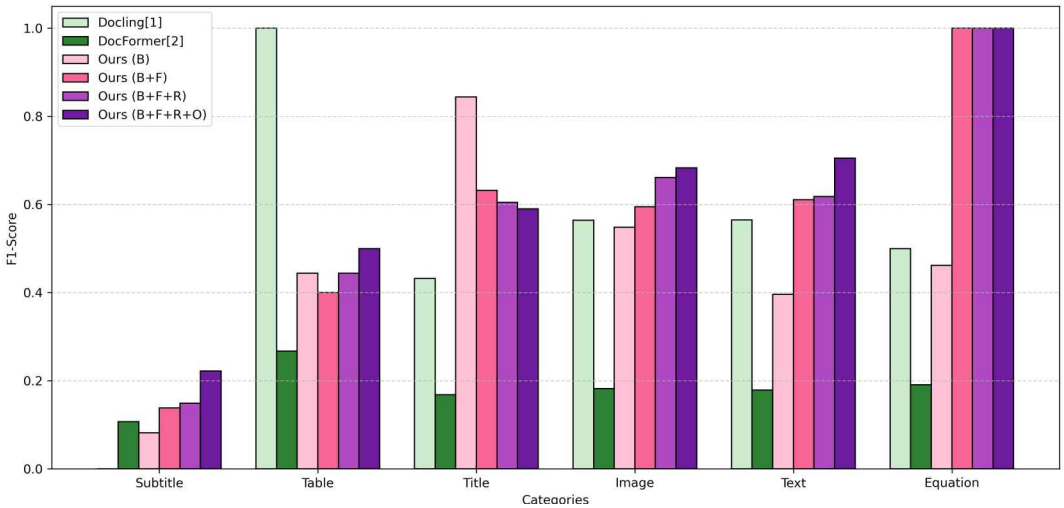


그림 6. 클래스별 바운딩 박스 검출 성능 비교

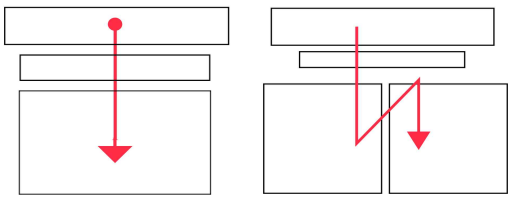


그림 5. 1단, 2단 문서의 읽기 순서 흐름도

Algorithm 2 Reading Order Rearrangement

```
procedure READING_ORDER(boxes, page_width)
    for box in boxes do                                  // iterate boxes
        if width(box) ≥ 0.6 × page_width then            // full-width element
            mark box as full-width
        end if
    end for
    divide remaining boxes into sections                 // split by full-width
    for section in sections do                           // iterate sections
        extract center x-coordinate of each box          // for clustering
        apply K-means (k = 2–6) to detect columns        // detect column groups
    end for
    if single-column layout then                         // single column
        sort boxes by (top, left)                        // top→bottom, left→right
    else                                                 // multi-column
        sort columns left→right
        sort boxes inside each column by (top, left)
    end if
    assign reading_order_id sequentially                 // assign order
end procedure
```

3. 실 험

3.1. 데이터셋 및 실험 구성

본 연구는 복잡한 문서 환경에서의 탐지 강건성을 증진시키기 위해, 자체 수집한 322건의 문서 데이터셋을 추가 활용하였다. 데이터셋은 세미나 발표 자료(PPT 형식, 209건), 학술 논문(57건), 학술대회 포스터(56건)로 구성되며, 각 문서에 대해 모든 객체를 바운딩 박스로 수작업 레이블링하였다. 본 데이터셋은 실제 문서에서 발생하는 비정형적 레이아웃 구조를 반영하도록 설계되었다. 예를 들어, ‘Title’과 ‘Subtitle’이 공존하는 문서, 본문 내 ‘Equation’이 포함된 문서, 단일·멀티 칼럼 혼합 문서, 시각적 요소의 밀집도가 높은 문서 등이 이에 해당한다. 전체 322건 중 272건을 학습에, 50건을 테스트에 할당하였다.

CoDU의 효과성을 검증하기 위해 먼저 Docling과 DocFormer를 대상으로 비교 실험을 진행하였으며, Ablation Study를 통해 각개 효과를 검증하였다. CoDU의 Baseline(B)은 DocStructBench로 사전 학습된 DocLayout-YOLO 기반 바운딩 박스 검출과 PaddleOCR 3.0 문자 인식으로 구성된다[3]. 본 연구는 Baseline에 미세 조정(F, DocLayout Fine-Tuning), 바운딩 박스 정제(R, Bounding-Box Refinement), 읽기 순서 재정렬(O, Reading Order Rearrangement)을 단계적으로 추가하여 성능 변화를 분석하였다. 미세 조정(F)은 자체 데이터셋 기반으로 바운딩 박스 검출 성능 향상을 목표로 하며, 바운딩 박스 정제(R)는 수식 재분류와 글머리 항목 세분화를 수행한다. 읽기 순서 재정렬(O)은 규칙 기반 알고리즘을 수행한다.

바운딩 박스 검출 성능 평가는 IoU ≥ 0.5 기준으로 예측 바운딩 박스와 정답 바운딩 박스를 매칭하여, 클래스별 Precision, Recall, F1-score를 계산하였다. OCR 성능 평가는 IoU ≥ 0.3 이상 겹치는 바운딩 박스 쌍을 대상으로, 문자열 간 유사도를 정규화된 편집 거리(Normalized Edit Distance, NED)로 계산하였다. NED는 두 문자열 간 최소 편집 거리를 문자열 길이로 정규화한 값으로, 값이 작을수록 인식 정확도가 높음을 의미한다. 읽기 순서 성능 평가는 IoU ≥ 0.5로 매칭된 바운딩 박스 쌍을 대상으로 수행하였다. 두 순서 간의 일치 정도는 NED로 계산하며 1-NED를 순서 유사도로 정의하고 매칭 비율을 곱해 최종 읽기 순서 성능 점수를 산출하였다.

3.2. 비교 실험

모델별 바운딩 박스 검출 성능을 비교한 결과와 모델별 OCR 성능과 읽기 순서 성능을 비교한 결과는 각각 표 1과 표 2에 나타내었다. 또한, 그림 6은 클래스별 바운딩 박스 검출 성능 비교를 나타낸다. 그림 6에서 F1-score 기준 ‘Title’에서 Docling 대비 +0.412, DocFormer 대비 +0.676 향상되었으며, ‘Image’는 Docling 대비 +0.111, DocFormer 대비 +0.493, ‘Equation’는 Docling 대비 +0.500, DocFormer 대비 +0.809 개선되었다. 특히, ‘Equation’같이 샘플 수가 적은 클래스에서도 안정적인 검출 성능을 보였다. 전체 바운딩 박스 검출 성능도 CoDU는 표 1과 같이 F1-score 0.617로 Docling 대비 +0.234, DocFormer 대비 +0.475 향상되었다. Precision과 Recall 모두 크게 개선해 정확한 탐지와 누락 최소화를 동시에 달성하였다.

OCR 성능은 표 2와 같이 1-NED 기준으로 평가하였다. CoDU는 ‘Text’에서 0.615로 최고 성능을 달성하였으며, Docling과 DocFormer가 지원하지 않는 ‘Subtitle’에서도 0.321의 문자 인식 정확도를 달성하였다. 읽기 순서 성능 또한, 표 2와 같이, CoDU가 0.469로 Docling 대비 +0.119, DocFormer 대비 +0.230 향상되었다. 이는 규칙 기반 알고리즘이 멀티 칼럼 및 복잡한 문서 환경에서도 효과적으로 작동함을 보여준다.

표 1. 모델별 바운딩 박스 검출 성능

평가 지표 / 모델	바운딩 박스 검출		
	Precision	Recall	F1-score
Docling[1]	0.361	0.441	0.383
DocFormer[2]	0.124	0.210	0.142
Ours(B)	0.456	0.518	0.463
Ours(B+F)	0.551	0.627	0.563
Ours(B+F+R)	0.583	0.616	0.580
Ours(B+F+R+O)	**0.591**	**0.706**	**0.617**

표 2. 모델별 OCR 성능과 읽기 순서 성능

평가 지표 / 모델	OCR 성능 (1-NED)			읽기 순서 성능 (1-NED)×coverage
	Title	Text	Subtitle	
Docling[1]	0.658	0.417	0.000	0.350
DocFormer[2]	0.299	0.215	0.000	0.239
Ours(B)	**0.762**	0.279	0.118	0.263
Ours(B+F)	0.482	0.488	0.192	0.333
Ours(B+F+R)	0.476	0.485	0.192	0.356
Ours(B+F+R+O)	0.491	**0.615**	**0.321**	**0.469**

3.3. Ablation Study

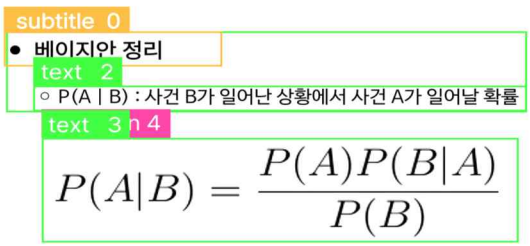


그림 7. Baseline으로 검출한 바운딩 박스 및 읽기 순서 예시

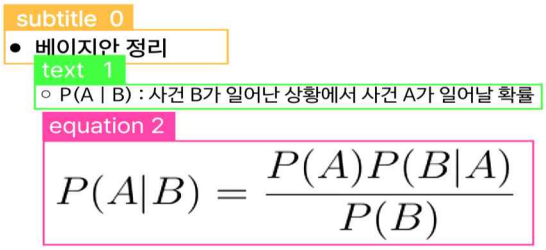


그림 8. CoDU로 검출한 바운딩 박스 및 읽기 순서 예시

CoDU의 각 구성 요소의 기여도 검증을 위해 Baseline(B)에 미세 조정(F), 바운딩 박스 정제(R), 읽기 순서 재정렬(O)을 단계적으로 추가하며 성능 변화를 분석하였다. Baseline(B) 대비, F1-score는 B+F에서 +0.100, B+F+R에서 +0.117, 모든 구성 요소를 포함한 B+F+R+O에서는 +0.154 상승하였다. 우선, B+F의 향상은 자체 구축한 복잡한 문서 데이터셋을 활용해 미세 조정을 통해 모델의 일반화 성능을 개선했음을 보여준다. 이후 R 단계를 추가한 B+F+R 조합은 바운딩 박스의 경계 정밀도를 높여 OCR 인식률 향상에 기여하였다. 마지막으로 O 단계까지 포함한 모든 모듈이 적용된 경우, 이전 조합들이 개선하지 못한 읽기 순서 성능을 향상시켜 구조적 일관성을 확보하였다. 결과적으로, Baseline(B)에 미세 조정(F)을 결합한 B+F 조합은 일반화 성능을 크게 개선하였으며, 바운딩 박스 정제(R)를 추가한 B+F+R 조합의 경우, OCR 인식률을 향상하였다. 마지막으로 읽기 순서 재정렬(O)까지 포함한 CoDU인 B+F+R+O 조합은 세 지표 모두에서 최고 성능을 달성하였다. 즉, 미세 조정(F)은 일반화 개선, 바운딩 박스 정제(R)는 OCR 성능 향상, 읽기 순서 재정렬(O)은 구조적 일관성 확보에 각각 기여하며, 구성 요소가 단계적으로 결합될수록 모델이 발전하였다.

4. 결 론

본 연구에서는 복잡한 문서 구조를 정밀하게 이해하기 위한 CoDU를 제안하였다. CoDU는 DocLayout-YOLO 기반 바운딩 박스 검출에 정제 과정과 읽기 순서 재정렬을 단계적으로 결합하여 높은 정확도의 문서 내용 인식을 수행할 수 있도록 하였다.

실험 결과, CoDU는 Docling과 DocFormer 대비 바운딩 박스 검출 F1-score에서 최대 +0.475, 읽기 순서 성능에서 최대 +0.230 향상되었다. OCR 성능은 'Text'와 'Subtitle'에서 최고 정확도를 달성하였으며, 'Equation'과 같이 샘플 수가 적은 클래스에서도 안정적인 검출 성능을 보였다. Ablation Study를 통해 미세 조정(F)이 F1-score +0.100으로 가장 큰 기여를 하였으며, 바운딩 박스 정제(R)와 읽기 순서 재정렬(O)이 각각 OCR 성능과 읽기 순서 성능 향상에 기여함을 확인하였다. 이는 각 구성 요소가 상호 보완적으로 작동하여 전체 시스템의 성능을 단계적으로 향상시킴을 보여준다.

CoDU는 세미나 발표 자료, 학술 논문, 학술대회 포스터 등 다양한 문서 유형에서 검증되었으며, 실제 문서 처리 환경에서의 범용성과 실용성을 입증하였다. 향후 연구에서는 CoDU를 통해 문서의 시각적·구조적 정보를 정교하게 추출한 뒤, 이를 RAG 구조와 결합하여 보다 정교한 문맥적 질의응답을 가능케 하는 지능형 시스템을 개발할 예정이다.

참 고 문 헌

[1] Livathinos, N., Auer, C., Lysak, M., Nassar, A., Dolfi, M., Vagenas, P., et al., "Docling: An Efficient Open-Source Toolkit for AI-Driven Document Conversion," *arXiv preprint arXiv:2501.17887,* 2025.

[2] Appalaraju, S., Jasani, B., Kota, B.U., Xie, Y., Manmatha, R., "DocFormer: End-to-End Transformer for Document Understanding," *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pp. 993-1003, 2021.

[3] Zhao, Z., Kang, H., Wang, B., He, C., "DocLayout-YOLO: Enhancing Document Layout Analysis through Diverse Synthetic Data and Global-to-Local Adaptive Perception," *arXiv preprint arXiv:2410.12628,* 2024.

[4] Pfitzmann, B., Auer, C., Dolfi, M., Nassar, A.S., Staar, P., "DocLayNet: A Large Human-Annotated Dataset for Document-Layout Segmentation," *Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, pp. 3743-3751, 2022.

[5] Cui, C., Sun, T., Lin, M., Gao, T., Zhang, Y., Liu, J., Wang, X., Zhang, Z., et al., "PaddleOCR 3.0 Technical Report," *arXiv preprint arXiv:2507.05595,* 2025.